

INSTITUTO FEDERAL DE EDUCAÇÃO, CIÊNCIA E TECNOLOGIA DE MINAS  
GERAIS

CAMPUS OURO PRETO

Marco Antonio do Nascimento

Previsão de Ações Brasileiras utilizando Redes Neurais LSTM e modelo GARCH

Trabalho de Conclusão de Curso

Ouro Preto

2024

MARCO ANTONIO DO NASCIMENTO

Previsão de Ações Brasileiras utilizando Redes Neurais LSTM e modelo GARCH

Trabalho de Conclusão de Curso apresentado ao curso de ESPECIALIZAÇÃO EM INTELIGÊNCIA ARTIFICIAL, ofertado pelo Instituto Federal de Educação, Ciência e Tecnologia de Minas Gerais - *Campus* Ouro Preto, como parte dos requisitos para a obtenção do título de ESPECIALISTA EM INTELIGÊNCIA ARTIFICIAL.

Orientadores: Prof. Dr. Carlos Alexandre Silva - IFMG Campus Sabará - Orientador  
Prof. Dr. Carlos Alberto Severiano Júnior - IFMG Campus Sabará - Coorientador

Ouro Preto

2024

---

N244p

Nascimento, Marco Antonio do.

Previsão de ações brasileiras utilizando redes neurais LSTM e modelo GARCH [manuscrito] / Marco Antonio do Nascimento. – 2024.  
32 f. : il.

Orientador: Carlos Alexandre Silva.

Coorientador: Carlos Alberto Severiano Júnior.

Trabalho de Conclusão de Curso (especialização) – Instituto Federal de Minas Gerais. *Campus* Ouro Preto, 2024.

1. Redes neurais (Computação). 2. Long Short-Term Memory (LSTM). 3. Ações (Finanças). I. Silva, Carlos Alexandre. II. Severiano Júnior, Carlos Alberto III. Instituto Federal de Minas Gerais. *Campus* Ouro Preto. IV. Título.

---

CDU: 004.8

Catálogo: Kelly Cristiane Santos Moraes - CRB-6/3217



**MINISTÉRIO DA EDUCAÇÃO  
SECRETARIA DE EDUCAÇÃO PROFISSIONAL E TECNOLÓGICA  
INSTITUTO FEDERAL DE EDUCAÇÃO, CIÊNCIA E TECNOLOGIA DE MINAS GERAIS  
Campus Ouro Preto**

**Diretoria de Pesquisa, Inovação e Pós-Graduação  
Coordenação do Curso de Pós-graduação em Inteligência Artificial**  
Rua Pandiá Calógeras, 898 - Bairro Bauxita - CEP 35400-000 - Ouro Preto - MG  
- [www.ifmg.edu.br](http://www.ifmg.edu.br)

**FOLHA DE APROVAÇÃO**

**Marco Antônio do Nascimento**

**PREVISÃO DE AÇÕES BRASILEIRAS UTILIZANDO REDES NEURAIS LSTM E  
MODELO GARCH**

Trabalho de Conclusão de Curso apresentado ao curso de ESPECIALIZAÇÃO EM INTELIGÊNCIA ARTIFICIAL, ofertado pelo Instituto Federal de Educação, Ciência e Tecnologia de Minas Gerais - *Campus* Ouro Preto, como parte dos requisitos para a obtenção do título de ESPECIALISTA EM INTELIGÊNCIA ARTIFICIAL.

Aprovado em 03 de dezembro de 2024, pela Banca Examinadora:

Prof. Dr. Carlos Alexandre Silva - IFMG Campus Sabará - Orientador  
Prof. Dr. Carlos Alberto Severiano Júnior - IFMG Campus Sabará - Coorientador  
Prof. Dra. Sabrina Moreira de Oliveira - IBMEC  
Prof. Dr. Johnatan Alves de Oliveira - UFLA

Ouro Preto, 03 de dezembro de 2024.



Documento assinado eletronicamente por **Carlos Alexandre Silva, Professor EBT**, em 15/12/2024, às 17:25, conforme Decreto nº 10.543, de 13 de novembro de 2020.



Documento assinado eletronicamente por **Carlos Alberto Severiano Júnior, Professor**, em 16/12/2024, às 07:10, conforme Decreto nº 10.543, de 13 de novembro de 2020.



Documento assinado eletronicamente por **Johnatan Alves de Oliveira, Usuário Externo**, em 16/12/2024, às 10:29, conforme Decreto nº 10.543, de 13 de novembro de 2020.



Documento assinado eletronicamente por **Sabrina Moreira de Oliveira, Usuário Externo**, em 14/02/2025, às 09:19, conforme Decreto nº 10.543, de 13 de novembro de 2020.



A autenticidade do documento pode ser conferida no site <https://sei.ifmg.edu.br/consultadocs> informando o código verificador **2125228** e o código CRC **3E71C39C**.

## **RESUMO**

O propósito deste trabalho é estimar o comportamento dos preços diários das principais ações do mercado de ações brasileiro no período entre 2000 e 2024, a partir de dois modelos: um modelo de Redes Neurais LSTM e um modelo Híbrido onde se insere a estimação de volatilidade GARCH junto ao modelo LSTM, denominado GARCH-LSTM. Como resultados, pode-se afirmar que o comportamento dos preços das séries financeiras examinadas foi adequadamente estimado tanto pelo modelo LSTM quanto pelo modelo LSTM/GARCH. No que tange a escolha do modelo ideal, verificou-se que a maior parte das ações analisadas, apresentaram melhores resultados de estimação junto ao modelo GARCH-LSTM indicando que ao se inserir a estimação de volatilidade no modelo, há uma melhora na previsão do comportamento dos preços de ações.

**Palavras-Chave:** Redes Neurais. LSTM. Volatilidade. GARCH. Mercado Acionário. Risco

## **ABSTRACT**

The purpose of this study is to estimate the daily price behavior of the main stocks in the Brazilian stock market during the period from 2000 to 2024 using two models: an LSTM Neural Network model and a Hybrid model that incorporates GARCH volatility estimation into the LSTM model, referred to as GARCH-LSTM. The results indicate that the price behavior of the analyzed financial series was adequately estimated by both the LSTM model and the LSTM/GARCH model. Regarding the choice of the ideal model, it was found that for most of the analyzed stocks, the GARCH-LSTM model provided better estimation results, suggesting that incorporating volatility estimation into the model improves the forecasting of stock price behavior.

**Keywords:** Neural Networks. LSTM. Volatility. GARCH. Stock Market. Risk

## 1. INTRODUÇÃO

A decisão de investir, seja num projeto de negócio ou mesmo num ativo financeiro, passa pela ideia de saber a rentabilidade do investimento frente a uma probabilidade de desempenho. Deste modo, os princípios econômicos têm em sua essência o processo de tomada de decisão, de modo a satisfazer os interesses de cada indivíduo.

Devido à gama de informações disponíveis a respeito do mercado de capitais nos últimos anos, diversas técnicas de aprendizado de máquina foram desenvolvidas com o objetivo de coleta, análise e previsão do comportamento dos preços do mercado de ações (FARIA, 2018). Tais técnicas dependem em sua essência dos hiperparâmetros, que são variáveis de treinamento definidas manualmente e determinadas antes do treinamento do modelo. Uma das técnicas mais utilizadas é a rede neural recorrente do tipo LSTM (*Long Short-Term Memory*), que, por ser recorrente, permite, a cada passo no sentido direto, não apenas o cálculo de uma previsão final cujo erro será minimizado, mas também a propagação de informações entre os passos. Dessa forma, em cada iteração, a rede combina informações do dado atual com dados anteriores, possibilitando a compreensão de relações temporais entre os diferentes dados de entrada. Nesse tipo de rede, os processos de propagação direta e retropropagação do erro (*backpropagation*) são mantidos e comumente utilizam hiperparâmetros de ativação (como Sigmóide, Tanh e Softmax), otimização (como Adam, Adadelta e RMSprop), tamanho, número de períodos, número de camadas ocultas, dentre outros. Dessa forma, ao se utilizar o modelo LSTM para se prever o comportamento dos preços de uma série temporal financeira, diversas configurações podem ser testadas e comparadas para otimizar o modelo.

Doravante, o mercado enfrenta naturalmente certa instabilidade ocasionada por fatores econômicos, políticos e sociais, fazendo com que os preços dos ativos financeiros sofram oscilações, denominada volatilidade. Segundo Bressan e Lima (2002), uma das alternativas para se reduzir a incerteza no processo de tomada de decisões econômicas é a utilização de modelos de previsão de séries temporais. Tais modelos são construídos a partir de processos estocásticos que buscam estimar uma determinada variável com base na estrutura de correlação de seus valores passados. No âmbito econômico, a redução de incerteza é de especial importância principalmente para os agentes financeiros inseridos num mercado de capitais cada vez mais globalizado e que está constantemente sujeito a distúrbios irregulares.



Dada a importância de se prever o comportamento dos preços de ativos financeiros, muitas abordagens desta previsão foram propostas na literatura, como nos estudos de Hansen e Lunde, 2005 e Wilhelmsson, 2006; e, apesar da volatilidade constituir uma ferramenta bastante utilizada pelos investidores para a mensuração de risco, sua estimativa leva a algumas dificuldades e requer precauções frente à sua interpretação.

Desta forma, o presente estudo tem o propósito de abordar dois instrumentos utilizados para a estimação de ativos financeiros, um com viés da inteligência artificial, especificamente o modelo de redes neurais LSTM de 15 variáveis, e outro no qual é adicionada ao modelo LSTM uma variável com viés estatístico que é a estimação da volatilidade desses ativos através do modelo GARCH, admitindo que a volatilidade do passado também pode influenciar a estimação do preço das ações para o futuro. Assim, tem-se como base de dados as ações brasileiras que possuem, em maio de 2024, mais de 1% de participação no mercado, totalizando 21 empresas, cujo período de análise está compreendido entre os anos de 2000 e 2024.

Os resultados encontrados foram sugestivos e apontaram que um modelo do tipo GARCH-LSTM, que incorpora termos de volatilidade condicional ao modelo de redes neurais, seria mais apropriado para se prever o comportamento dos preços da maioria das 21 ações analisadas.

Ademais, este trabalho pretende fornecer ao investidor informações capazes de ajudá-los na tomada de decisão, principalmente no que tange à reação e persistência de volatilidade advindas de choques aleatórios originados por questões que afetam de certa forma o mercado de ações, como questões políticas, econômicas ou sociais.

## **2. REFERENCIAL TEÓRICO**

### **2.1. Modelo GARCH**

Em finanças, segundo Enders (2014), a volatilidade é geralmente entendida como uma medida estatística que aponta a frequência e intensidade das oscilações nos preços dos ativos num determinado período. Isso faz com que ela possa ser usada para mensurar o risco de um investimento. Como a volatilidade da série dos retornos de ativos financeiros é considerada

instável ao longo do tempo, novos modelos específicos para séries temporais financeiras tendem a ser aplicados.

À luz deste desafio, o grande avanço para descrever estas séries foi o desenvolvimento de modelos com heteroscedasticidade condicional autorregressiva (ARCH). A principal diferença entre essa abordagem e a análise clássica de séries temporais é a modelagem da variância condicional, em função da quantidade de informações disponíveis. Através do trabalho revolucionário de Engle (1982), a análise da volatilidade dos dados do mercado financeiro recebeu um impulso decisivo.

Outro marco, neste campo, representa a generalização do modelo de Engle (1982), denominado GARCH (*Generalized Autoregressive Conditional Heteroskedasticity*), desenvolvida por Bollerslev (1986), que criou as condições para uma aplicação prática com a transferência do princípio da parcimônia de Box e Jenkins para o modelo. Com este propósito, de acordo com Engle (2001), os modelos ARCH e GARCH enxergam a heteroscedasticidade não como um problema a ser corrigido, mas sim como uma variância a ser moldada, resultando numa previsão calculada para a variância de cada termo de erro.

Bollerslev (1986) descreveu os parâmetros da variância condicional de forma reduzida, de modo a aplicá-lo mais facilmente na previsão do risco de séries financeiras. Esta previsão, então, tem fundamental importância, visto que a variável dependente é o retorno sobre um ativo ou carteira e a variação do retorno representa o nível de risco desses retornos.

Bollerslev (1986) desenvolveu uma técnica que permite que a variância condicional seja um processo ARMA e o erro passa a ser descrito como:

$$\varepsilon_t = v_t \sqrt{h_t}, \quad (1)$$

onde

$$\sigma_v^2 = 1, \quad (1.1)$$

e

$$h_t = \alpha_0 + \sum_{i=1}^q \alpha_i \varepsilon_{t-i}^2 + \sum_{i=1}^p \beta_i h_{t-i} \quad (1.2)$$

em que  $q$  representa a ordem do processo autorregressivo e  $p$  representa a ordem do processo de médias móveis. Usando operadores *lag* e polinomiais, a equação (1.2) também pode ser expressa da seguinte forma:

$$h_t = \alpha_0 + A(L)\alpha_i\varepsilon_t^2 + B(L)h_t \quad (1.3)$$

onde

$$\begin{aligned} p &\geq 0 \text{ e } q > 0, \\ \alpha_0 &> 0; \alpha_i \geq 0; i = 1, \dots, q \\ \beta_i &\geq 0; i = 1, \dots, q \end{aligned}$$

O modelo GARCH (1,1) foi escolhido para este estudo devido à sua simplicidade e eficácia comprovada em diversas aplicações financeiras. Segundo Bollerslev (1986), por exemplo, o GARCH (1,1) é particularmente fácil de manusear e superior a outros modelos financeiros de séries temporais. Além disso, Wilhelmsson (2006) demonstrou o poder preditivo do GARCH (1,1) através dos retornos do índice S&P 500. Hansen e Lunde (2005) também não encontraram evidências de que o GARCH (1,1) seja superado por modelos mais sofisticados, desconsiderando efeitos de alavancagem.

No entanto, é importante reconhecer que existem variantes do modelo GARCH, como o EGARCH e o TGARCH, que podem capturar assimetrias na volatilidade. O EGARCH, por exemplo, permite que a volatilidade responda de forma diferente a choques positivos e negativos, enquanto o TGARCH modela a volatilidade de forma que choques negativos tenham um impacto maior do que choques positivos de mesma magnitude.


## 2.2. Redes Neurais LSTM

Nos últimos anos, profissionais do mercado têm recorrido ao aprendizado de máquina e ao aprendizado profundo para melhor compreender a dinâmica do mercado e, em alguns casos, até mesmo criar sistemas de negociação automatizados baseados nesses algoritmos. Como o GARCH continua sendo o principal modelo utilizado para a previsão de volatilidade de ativos financeiros, como descrito por Hansen e Lunde (2005) que em seus estudos não encontraram evidências de que o modelo GARCH (1,1) seja superado por modelos mais sofisticados, desconsiderando efeitos de alavancagem, novos métodos de aprendizado profundo, como

LSTM, podem ser utilizados conjuntamente com o GARCH para se estimar o comportamento dos preços de séries temporais financeiras.

De acordo com Hochreiter e Schmidhuber (1997), a *Long Short-Term Memory* (LSTM) é uma variante de uma rede neural recorrente comumente usada para previsões de séries temporais, a fim de lidar com o problema do gradiente que se verifica nas RNNs tradicionais. As LSTMs são frequentemente usadas para certos problemas de Processamento de Linguagem Natural, já que uma série de sentenças pode ser vista como uma série temporal com algum grau de autocorrelação, uma vez que as palavras geralmente dependem das palavras anteriores e posteriores a elas.

Para esse fim, segundo Hochreiter e Schmidhuber (1997), uma unidade LSTM contém uma célula de memória, juntamente com portas de entrada e saída para controlar o fluxo de informações para dentro e para fora da unidade LSTM. Uma versão moderna da LSTM, desenvolvida por Gers, Schmidhuber e Cummins (2000), inclui uma “porta de esquecimento”, que permite que a rede aprenda a descartar informações que não são mais relevantes no processo de previsão. Isso impede que o estado da célula cresça indefinidamente, o que pode levar a problemas de sobrecarregamento de memória e dificuldades no aprendizado a longo prazo. Outra variante, demonstrada por Chung et al. (2014), chamada Gated Recurrent Unit (GRU), não possui uma porta de saída. Abaixo pode ser observada a diferença entre um modelo de rede neural recorrente (a), um modelo LSTM (b) e um modelo GRU (c):



**Figura 1:** Modelos de redes neurais

**Fonte:** Adaptado de Chung et al. (2014)

Como discutido acima, a capacidade das LSTMs de lidar com séries temporais que apresentam volatilidade inconsistente, mostra que esse modelo pode ser utilizado para a previsão de séries temporais de ativos financeiros. Sang e Di Pierro (2018) usaram a LSTM para prever séries temporais financeiras no mercado de ações, usando tanto entradas de análise de séries temporais

tradicionais como métricas de análise técnica como características. Xiong, Nichols e Shen (2015) também tiveram sucesso na previsão de séries temporais financeiras através da LSTM tradicional, assim como Gao, Chai e Liu (2017) que estimaram o comportamento de ações utilizando as RNNs.

Desta forma, o presente trabalho utiliza a versão clássica do modelo LSTM, desenvolvida por Hochreiter e Schmidhuber (1997) com o objetivo de verificar qual a capacidade de previsão de séries temporais financeiras de um modelo LSTM “puro” comparativamente a um modelo LSTM híbrido que se utiliza das estimações de um modelo GARCH.

### **3. METODOLOGIA**

Nessa seção, será explanada a abordagem metodológica para a previsão do comportamento dos preços das principais ações da bolsa de valores brasileira (B3). Como método de estudo, optou-se pelo uso da análise de séries temporais, definidas como “sequências de dados quantitativos relativos a momentos específicos e estudados segundo sua distribuição no tempo” (Wiener, 1966), ratificando que tal método se aplica a diferentes finalidades e campos de conhecimento, desde a forma de aperfeiçoar o fluxo de estoque numa empresa, a programação de compra de matéria prima ou mesmo para dimensionar o fluxo de vendas em um empreendimento comercial. (Antunes & Cardoso, 2015).

Dentro dos modelos de análise de séries temporais financeiras, utiliza-se neste trabalho o modelo de rede neural LSTM, introduzido por Hochreiter e Schmidhuber (1997).

#### **3.1. Base de Dados**

A base de dados do presente estudo refere-se às principais empresas listadas na bolsa de valores brasileira e foi coletada utilizando a plataforma *Yahoo Finance*<sup>1</sup>. Para este estudo, foram selecionadas as empresas que, em maio de 2024, representaram mais de 1% do volume total

---

<sup>1</sup> <https://finance.yahoo.com>

negociado na bolsa, totalizando 21 empresas. O critério de 1% foi escolhido para garantir que a análise seja focada nas empresas de maior relevância e liquidez no mercado, considerando que ativos com volumes negociados muito baixos podem apresentar alta volatilidade e comportamentos atípicos, o que poderia distorcer os resultados ou torná-los menos representativos para aplicações práticas. Abaixo, seguem as empresas selecionadas:

**Tabela 1:** Empresas com mais de 1% em participação

<b>Empresa</b>	<b>Código</b>	<b>Empresa</b>	<b>Código</b>
Ambev	ABEV3	JBS	JBSS3
Banco BTG Pactual	BPAC11	Petrobras	PETR3
Banco do Brasil	BBAS3	Petrobras	PETR4
BB Seguridade	BBSE3	PetroRio	PRIO3
B3	B3SA3	Raia Drogasil	RADL3
Bradesco	BBDC4	Rede D'Or	RDOR3
Equatorial Energia	EQTL3	Localiza	RENT3
Eletrobras	ELET3	Suzano	SUZB3
Embraer	EMBR3	Vale	VALE3
Itaúsa	ITSA4	Weg	WEGE3
Itaú Unibanco	ITUB4		

**Fonte:** Dados da pesquisa.

As séries temporais cobrem o período de 1º de janeiro de 2000 a 7 de maio de 2024 e incluem um total de 15 variáveis para o primeiro modelo, que aqui será nomeado como “Modelo LSTM Puro” e 16 variáveis para o segundo modelo, denominado “Modelo Híbrido GARCH-LSTM”. O intervalo escolhido foi definido com o objetivo de incluir um histórico suficientemente longo para capturar diferentes regimes de mercado, ciclos econômicos e eventos significativos que podem influenciar os preços das ações. Essa abrangência temporal permite que os modelos aprendam padrões complexos que podem ser úteis na previsão de séries financeiras.

Para o Modelo LSTM Puro, as variáveis são:

**Tabela 2:** Variáveis do modelo

<b>Variável</b>	<b>Descrição</b>
Preço de abertura	O primeiro preço pelo qual uma ação foi negociada no início de um determinado dia de negociação.
Preço máximo do dia	O maior preço pelo qual uma ação foi negociada durante o dia.
Preço mínimo do dia	O menor preço pelo qual uma ação foi negociada durante o dia.
Preço de fechamento	O último preço pelo qual uma ação foi negociada no final de um dia de negociação.
Preço de fechamento ajustado	O preço de fechamento ajustado para eventos corporativos como dividendos, desdobramentos de ações ou fusões.
Retorno diário absoluto	Diferença entre os preços de fechamento de dois dias consecutivos, representando a variação absoluta do preço.
Retornos diário absoluto quadrado	O retorno diário absoluto elevado ao quadrado, frequentemente usado para medir a volatilidade.
Logaritmo do retorno absoluto	Diferença dos logaritmos naturais dos preços de fechamento de dois dias consecutivos, usada para suavizar variações extremas.
Variação percentual do retorno diário	Diferença percentual entre os retornos diários de dois dias consecutivos, representando a taxa de variação.
Log da variação % do retorno diário	Logaritmo natural da variação percentual do retorno diário, usado para suavizar as flutuações de alta frequência.
Desvio pad. do log dos retornos (30 dias)	Desvio padrão dos logaritmos dos retornos diários calculado em janelas móveis de 30 dias, usado para medir a volatilidade.
Desvio pad. do log dos retornos (60 dias)	Desvio padrão dos logaritmos dos retornos diários calculado em janelas móveis de 60 dias, usado para medir a volatilidade.
Variância dos preços de fechamento (30 dias)	Variância dos preços de fechamento calculada em janelas móveis de 30 dias, usada para medir a dispersão dos preços.
Variância dos preços de fechamento (6 dias)	Variância dos preços de fechamento calculada em janelas móveis de 6 dias, usada para medir a dispersão dos preços em curto prazo.

Variável	Descrição
ROC do preço de fechamento (10 dias)	Rate of Change (ROC) no preço de fechamento em uma janela de 10 dias, usada para medir a taxa de variação do preço.

*Fonte:* dados da pesquisa

Para o Modelo Híbrido GARCH-LSTM, acrescentou-se a seguinte variável:

- Estimação da volatilidade diária calculada a partir do modelo GARCH(1,1). O modelo GARCH foi aplicado aos dados de variação percentual para modelar a volatilidade condicional. Assim, a volatilidade condicional gerada pelo modelo GARCH foi usada como uma entrada adicional no modelo de rede neural.

Cabe destacar que após a coleta dos dados, quaisquer valores nulos resultantes foram removidos e por fim, para o cumprimento dos objetivos, necessita-se de softwares computacionais a fim de executar os testes, análises, estimacão e modelagem dos dados. Para tanto, utilizou-se a plataforma computacional *Google Colab*, em linguagem *Python*, com pacotes específicos de séries temporais.

### 3.2. Preparação dos Dados para Redes Neurais

Os dados foram normalizados através da normalização Min-Max para garantir que todas as características tivessem a mesma escala, o que é crucial para o treinamento eficiente de modelos de redes neurais. Para séries temporais financeiras, onde a distribuição dos dados pode variar significativamente, a normalização Min-Max preserva a relação entre os valores, o que é crucial para capturar padrões temporais. Sua fórmula é dada por:

$$X_{norm} = \frac{x - \mu}{x_{max} - x_{min}},$$

onde:

- $X$  é o valor original da variável.
- $\mu$  é a média dos valores da variável.
- $x_{max}$  é o valor máximo da variável.



- $x_{min}$  é o valor mínimo da variável.

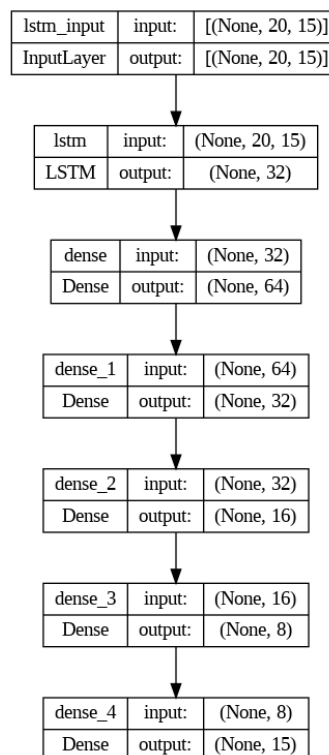
Em seguida, os dados foram organizados em sequências temporais para alimentar os modelos LSTM. Utilizou-se uma janela deslizante de 20 dias para criar sequências de entrada e saída:

- Sequências de Entrada (X): Conjunto de 20 dias consecutivos de dados normalizados.
- Sequências de Saída (Y): Dados do dia seguinte ao final da sequência de entrada.

Os dados foram divididos em conjuntos de treinamento (80%) e teste (20%).

### 3.3. Construção e Treinamento dos Modelos LSTM

A arquitetura do modelo utilizado neste estudo é composta por uma combinação de uma camada *Long Short-Term Memory* (LSTM) e várias camadas densas (*fully connected*), como ilustrado na Figura 2. Tal arquitetura foi baseada nos experimentos de Liu e So (2020) e adaptadas para a realidade do trabalho.



**Figura 2:** Arquitetura do modelo

**Fonte:** Dados de pesquisa

A camada de entrada do modelo processa dados sequenciais com 20 passos de tempo, cada um contendo 15 *features* (variáveis). A camada LSTM, com 32 unidades, é responsável por capturar as dependências temporais nos dados, preservando informações importantes ao longo da sequência. Em seguida, os dados passam por uma série de cinco camadas densas, que gradualmente reduzem a dimensionalidade dos dados de 64 para 15 unidades na última camada. Assim, resumidamente, tem-se uma camada LSTM com 32 unidades, seguida por quatro camadas densas (64, 32, 16, 8 unidades) com função de ativação *tanh* e uma camada de saída. Essa redução progressiva permite que o modelo capture padrões complexos nos dados, ajustando-se de maneira eficiente às variações presentes nas séries temporais. Ademais, os modelos foram treinados por 100 épocas com um tamanho de *batch* de 100, utilizando 20% dos dados de treinamento para validação.

O modelo foi executado 10 vezes para cada uma das ações, tanto para o LSTM puro quanto para o GARCH-LSTM, e os resultados médios dos erros (MSE, RMSE e MAE) foram utilizados para avaliar a adequação de cada modelo às diferentes séries temporais. A escolha por realizar 10 execuções foi baseada na análise de convergência dos resultados: a partir desse número de repetições, os valores obtidos apresentaram pouca variação, indicando estabilidade nos erros médios e tornando desnecessário um número maior de execuções. Optou-se pela não utilização do MAPE (Mean Absolute Percentage Error) por ter se apresentado extremamente alto em situações quando os valores reais são próximos de zero, o que pode distorcer a avaliação do modelo.

No que tange a arquitetura do modelo GARCH-LSTM, ressalta-se que ela é similar ao modelo LSTM Puro, diferenciando pela quantidade de features, no qual foi incluído uma variável adicional que é a volatilidade condicional estimada pelo modelo GARCH.

### 3.4. Avaliação do Modelo

Os modelos foram avaliados utilizando os dados de teste. As previsões do comportamento do preço das ações foram comparadas com o comportamento real do preço destas ações, e as seguintes métricas de erro foram calculadas a fim de verificar o grau de assertividade dos modelos:

- **Erro Quadrático Médio (MSE):** Mede a média dos quadrados dos erros ou desvios, ou seja, a diferença entre os valores previstos e os valores observados.

- **Raiz do Erro Quadrático Médio (RMSE):** Raiz quadrada do MSE, fornece uma medida de erro na mesma escala que os dados originais.
- **Erro Absoluto Médio (MAE):** Média das diferenças absolutas entre os valores previstos e observados.

Devido à natureza estocástica do modelo LSTM, em que os resultados podem variar a cada execução, foi adotada a estratégia de rodar cada um dos modelos (LSTM Puro e GARCH-LSTM) 10 vezes para cada uma das 21 ações analisadas. Para cada execução, foram calculados os erros médios absolutos (MAE), os erros quadráticos médios (MSE) e as raízes dos erros quadráticos médios (RMSE). A média desses valores foi então utilizada para comparar a performance dos modelos em cada ação, permitindo uma avaliação mais robusta sobre qual modelo se adequa melhor a cada série temporal específica.

## 4. RESULTADOS

Nesta seção são apresentados os resultados da pesquisa, obtidos através da metodologia descrita acima, com a utilização da plataforma computacional *Google Colab*, em linguagem *Python*, onde o modelo LSTM Puro e o modelo Híbrido GARCH-LSTM foram comparados para determinar qual apresentou melhor desempenho na previsão dos preços das ações. A análise incluiu uma comparação detalhada das métricas de erro e a avaliação visual das previsões em relação aos dados reais. Além disso, os resultados mostraram que a média das métricas de erro (MSE, RMSE e MAE) calculadas a partir de 10 execuções apresentou consistência e permitiu uma comparação robusta entre os modelos LSTM puro e GARCH-LSTM. A Tabela 3 demonstra que essa abordagem é eficaz para avaliar a adequação de cada modelo às diferentes séries temporais.

### 4.1. Visualização Gráfica

A análise visual dos gráficos do comportamento dos preços de uma ação é uma ferramenta fundamental em finanças e investimentos. No contexto específico deste trabalho, a ideia será comparar as previsões gráficas dos dois modelos comparativamente aos dados reais.


Dessa forma, foram analisadas 21 ações utilizando os modelos propostos e para cada uma dessas ações, foram gerados gráficos que ilustram o comportamento dos preços reais em comparação com as previsões. No entanto, para manter o foco e evitar que o trabalho se torne excessivamente extenso, optou-se por apresentar apenas uma amostra representativa desses gráficos. Assim, foram apresentadas duas ações que obtiveram melhores resultados no modelo LSTM Puro, duas ações com melhores resultados no modelo GARCH-LSTM, e duas ações cujos resultados foram similares, ou seja, apresentaram menos de 1% de variação dos erros comparativamente.

#### **4.1.1. Ações com melhores resultados junto ao modelo LSTM Puro**

##### **4.1.1.1. Petrobras (PETR4)**

Observa-se no gráfico de PETR4 (Figura 3) que a linha vermelha, que corresponde às previsões do modelo LSTM Puro, tende a acompanhar de forma mais próxima a linha cinza, do comportamento real do preço da ação, ao longo de todo o período analisado.

Em contrapartida, a linha azul, representando as previsões do modelo GARCH-LSTM, apresenta maior dispersão em relação ao preço real, indicando que o GARCH-LSTM pode estar tendo dificuldade em capturar as oscilações mais rápidas do mercado, resultando em previsões menos precisas.



**Figura 3:** Comportamento gráfico do ativo PETR4

**Fonte:** Dados da pesquisa


Verifica-se ainda que em períodos como o que compreende os anos de 2023 a 2024, o modelo LSTM Puro parece se ajustar mais rapidamente e de forma mais precisa à tendência de alta observada, enquanto o GARCH-LSTM mostra uma maior defasagem e desvio em relação ao comportamento real. Em contraste, o modelo GARCH-LSTM, apesar de capturar a direção geral da tendência, frequentemente superestima ou subestima os preços.

Portanto, para o caso específico da PETR4, o modelo LSTM Puro é preferível, uma vez que proporciona previsões mais alinhadas com o comportamento real do mercado, tornando-se uma ferramenta potencialmente mais útil para análises e tomadas de decisão baseadas em previsões de preços.

#### **4.1.1.2. B3 (B3SA3)**

Tal como no caso anterior, o LSTM Puro demonstra uma maior proximidade com os valores reais ao longo de todo o período, especialmente em períodos de queda acentuada e recuperação, como observado no primeiro semestre de 2021 e em várias outras flutuações ao longo do período, conforme demonstrado na figura 4. Isso sugere que o modelo LSTM Puro foi mais

eficaz em replicar as oscilações reais do preço da ação B3SA3.



**Figura 4:** Comportamento gráfico do ativo B3SA3

**Fonte:** Dados da pesquisa

Durante períodos de alta volatilidade, como no início de 2021 e no final de 2023, o modelo LSTM Puro se ajusta de forma mais precisa às variações do mercado, enquanto o modelo GARCH-LSTM mostra previsões que descolam do comportamento do preço e que por todo o gráfico observa-se uma superestimação das variações.


Dessa forma, verifica-se que, para a ação B3SA3, o modelo LSTM Puro é preferível ao GARCH-LSTM, proporcionando previsões que refletem de maneira mais fiel o comportamento real dos preços.

#### **4.1.2. Ações com melhores resultados junto ao modelo GARCH-LSTM**

##### **4.1.2.1. Bradesco (BBDC4)**

Na figura 5, o GARCH-LSTM está mais próximo do comportamento real em comparação ao modelo LSTM Puro, sugerindo que ele conseguiu capturar melhor as flutuações e tendências

dos preços da ação BBDC4 ao longo do tempo.



**Figura 5:** Comportamento gráfico do ativo BBDC4

**Fonte:** Dados da pesquisa


Em períodos em que há alta volatilidade, como no início de 2021 e em meados de 2022, o GARCH-LSTM se ajusta mais precisamente às mudanças bruscas de preço, ao passo que o LSTM Puro destoa dos preços reais especialmente durante as variações mais significativas.

Em momentos específicos, como durante a queda de preço no final de 2023 e no início de 2024, o GARCH-LSTM refletiu com maior precisão as mínimas e máximas observadas nos dados reais, enquanto o LSTM Puro apresentou maior discrepância nesses pontos, com previsões que superestimam os preços.

#### 4.1.2.2. Vale (VALE3)

Similarmente, à situação anterior, a previsões do modelo GARCH-LSTM segue mais de perto o comportamento real dos preços de VALE3, conforme pode ser visto na figura 6, em

comparação ao LSTM Puro. Pode-se verificar que o modelo LSTM Puro apresenta desvios maiores em relação aos valores reais, especialmente entre o final de 2021 até o período final da análise (maio de 2024). Esses desvios são visíveis nas áreas onde a linha vermelha se afasta significativamente da linha cinza.



**Figura 6:** Comportamento gráfico do ativo VALE3

**Fonte:** Dados da pesquisa

Assim sendo, o gráfico sugere que a combinação do modelo GARCH-LSTM ajuda a suavizar as flutuações bruscas e a fornecer previsões mais confiáveis em relação a captura da dinâmica real dos preços.


#### **4.1.3. Ações com resultados semelhantes para os dois modelos**

##### **4.1.3.1. Itaúsa (ITSA4)**

Com relação ao comportamento dos preços da ITSA4, verifica-se na figura 7 que ambos os modelos se comportaram de forma similar quanto à previsão dos preços. Em praticamente todo



o período de análise, o preço real do ativo permaneceu acima das estimativas feitas pelos modelos e, além disso, verifica-se que não há como concluir sobre qual modelo obteve maior assertividade.




**Figura 7:** Comportamento gráfico do ativo ITSA4

**Fonte:** Dados da pesquisa

Dessa forma, ambos os modelos apresentam desvios em relação aos valores reais, mas esses desvios são pequenos e ocorrem em diferentes momentos, reforçando a ideia de que a escolha entre os modelos pode ser indiferente.

#### 4.1.3.2. PetroRio (PRIO3)

A mesma análise feita em ITSA4, pode ser verificada em PRIO3, dado que em alguns períodos, a previsão do LSTM Puro aproxima mais do preço real, enquanto que em outros momentos, o modelo GARCH-LSTM apresenta maior eficácia na captura das flutuações reais.



**Figura 8:** Comportamento gráfico do ativo PRI03

**Fonte:** Dados da pesquisa

O destaque para esse gráfico, está no fato de que ambos os modelos fizeram boas previsões até o primeiro semestre de 2023. Contudo, há um descolamento das previsões de ambos os modelos após o referido período, podendo ser justificado pelo fato de ter havido uma lateralização dos preços, o que demonstra uma ineficiência na captura dos preços reais em momentos de baixa volatilidade.

#### **4.2. Erro de Previsão: Comparação das métricas de erro (MSE, RMSE, MAE) entre os dois modelos.**

A comparação das métricas de erro, como o Erro Quadrático Médio (MSE), a Raiz do Erro Quadrático Médio (RMSE) e o Erro Absoluto Médio (MAE), é fundamental para a análise de dados e desenvolvimento de modelos. No presente estudo, analisar as métricas de erro entre dois modelos permite avaliar qual modelo faz previsões mais precisas em comparação aos

dados reais observados. O MSE, RMSE e MAE medem o desvio das previsões em relação aos valores reais, e quanto menor forem os erros, mais preciso é o modelo.

Assim sendo, busca-se agora identificar qual dos dois modelos (LSTM Puro e GARCH-LSTM) apresentou melhor desempenho quando se analisa o MAE, RMSE e MSE. Vale aqui destacar que para a construção da Tabela 2 foi necessária a extração da média de 10 execuções de cada um dos modelos para todas as 21 ações a fim de identificar qual dos dois modelos, LSTM Puro ou GARCH-LSTM, apresentou melhor desempenho em termos de MAE, RMSE e MSE. Essa abordagem permitiu minimizar a variabilidade inerente às execuções do modelo LSTM, onde cada execução apresenta um novo resultado. Dessa forma, foi possível determinar com maior segurança qual modelo é mais adequado para cada uma das ações analisadas. Abaixo, são resultados encontrados para as médias calculadas:

*Tabela 3:* Média das 10 execuções dos erros obtidos

<b>Ação</b>	<b>MSE (LSTM Puro)</b>	<b>RMSE (LSTM Puro)</b>	<b>MAE (LSTM Puro)</b>	<b>MSE (GARCH- LSTM)</b>	<b>RMSE (GARCH- LSTM)</b>	<b>MAE (GARCH- LSTM)</b>
ABEV3	0,00261566	0,050281	0,045169	0,002962	0,053634	0,049704
B3SA3	0,0019322	0,041654	0,03896	0,004154	0,059745	0,057426
BBAS3	0,00379188	0,056879	0,044024	0,002967	0,050773	0,035925
BBDC4	0,00056515	0,023088	0,018152	0,000433	0,02028	0,015353
BBSE3	0,00072856	0,026854	0,020589	0,000784	0,0278	0,021751
BPAC11	0,00122637	0,033999	0,026469	0,001185	0,033903	0,026313
ELET3	0,00252084	0,047678	0,041089	0,001921	0,042554	0,036226
EMBR3	0,00096775	0,030826	0,01771	0,000884	0,029581	0,017174
EQTL3	0,02266338	0,148152	0,133392	0,02272	0,148014	0,133407
ITSA4	0,00206818	0,045065	0,03363	0,0021	0,044803	0,035097
ITUB4	0,00182524	0,040958	0,033402	0,001661	0,03953	0,029731
JBSS3	0,01358346	0,114455	0,083528	0,015374	0,122663	0,088828
PETR3	0,00139045	0,035732	0,025122	0,001036	0,031414	0,021995
PETR4	0,0010301	0,030671	0,021571	0,001579	0,037293	0,026438

<b>Ação</b>	<b>MSE (LSTM Puro)</b>	<b>RMSE (LSTM Puro)</b>	<b>MAE (LSTM Puro)</b>	<b>MSE (GARCH- LSTM)</b>	<b>RMSE (GARCH- LSTM)</b>	<b>MAE (GARCH- LSTM)</b>
PRI03	0,00121209	0,034815	0,026838	0,000708	0,026601	0,020377
RADL3	0,0357767	0,180285	0,168096	0,031654	0,169042	0,156122
RDOR3	0,01234193	0,094525	0,087906	0,007821	0,070919	0,065471
RENT3	0,05934801	0,241287	0,234972	0,067519	0,250814	0,244372
SUZB3	0,00186813	0,029366	0,024239	0,002471	0,031859	0,025347
VALE3	0,00281444	0,050162	0,040486	0,00193	0,043307	0,032365
WEGE3	0,05984397	0,243779	0,220317	0,053506	0,229362	0,207307

*Fonte:* Dados de pesquisa

Para uma melhor apresentação dos resultados, a tabela 3 demonstra qual o melhor modelo encontrado para cada uma das 21 ações:

**Tabela 3:** Comparação dos erros

<b>Ação</b>	<b>Melhor Modelo (MSE)</b>	<b>Melhor Modelo (RMSE)</b>	<b>Melhor Modelo (MAE)</b>
ABEV3	LSTM Puro	LSTM Puro	LSTM Puro
B3SA3	LSTM Puro	LSTM Puro	LSTM Puro
BBAS3	GARCH- LSTM	GARCH-LSTM	GARCH-LSTM
BBDC4	GARCH- LSTM	GARCH-LSTM	GARCH-LSTM
BBSE3	LSTM Puro	LSTM Puro	LSTM Puro
BPAC11	GARCH- LSTM	GARCH-LSTM	GARCH-LSTM
ELET3	GARCH- LSTM	GARCH-LSTM	GARCH-LSTM
EMBR3	GARCH- LSTM	GARCH-LSTM	GARCH-LSTM

Ação	Melhor	Melhor Modelo (RMSE)	
	Modelo (MSE)	Melhor Modelo (MAE)	
EQTL3*	LSTM Puro	GARCH-LSTM	LSTM Puro
ITSA4*	LSTM Puro	GARCH-LSTM	LSTM Puro
ITUB4	GARCH-LSTM	GARCH-LSTM	GARCH-LSTM
JBSS3	LSTM Puro	LSTM Puro	LSTM Puro
PETR3	GARCH-LSTM	GARCH-LSTM	GARCH-LSTM
PETR4	LSTM Puro	LSTM Puro	LSTM Puro
PRI03*	GARCH-LSTM	GARCH-LSTM	LSTM Puro
RADL3	GARCH-LSTM	GARCH-LSTM	GARCH-LSTM
RDOR3	GARCH-LSTM	GARCH-LSTM	GARCH-LSTM
RENT3	LSTM Puro	LSTM Puro	LSTM Puro
SUZB3	LSTM Puro	LSTM Puro	LSTM Puro
VALE3	GARCH-LSTM	GARCH-LSTM	GARCH-LSTM
WEGE3	GARCH-LSTM	GARCH-LSTM	GARCH-LSTM

**Fonte:** Dados da pesquisa

Nota: \* = empresas que apresentaram uma diferença menor ou igual a 1% entre os dois modelos

Nessas tabelas, “LSTM Puro” e “GARCH-LSTM” indicam o modelo que apresentou os melhores resultados para MSE, RMSE e MAE em cada ação. Em (\*) estão marcadas as 3 empresas (EQTL3, ITSA4 e PRI03) que apresentaram uma diferença menor ou igual a 1% entre os dois modelos, o que significa que investidor pode ficar indiferente na escolha de um modelo em detrimento do outro. Verifica-se também que essas mesmas empresas apresentaram mudança na escolha do melhor modelo, a depender de qual a medida de erro será utilizada. A

empresa EQTL3, demonstrou uma melhor previsão para o modelo LSTM Puro, caso seja utilizado o MSE e MAE mas por outro lado apresentou um melhor resultado para o modelo GARCH-LSTM na utilização do RMSE. A mesma análise pode ser feita com a ação ITSA4. No caso da empresa PRIO3, os valores do MSE e RMSE demonstraram uma melhor previsão para o modelo GARCH-LSTM e já a medição do MAE demonstrou que o modelo LSTM Puro obteve o melhor resultado.

Assim sendo, a escolha pelo melhor modelo utilizando a média dos erros (MSE, RMSE e MAE), revelou que:

- MSE (Mean Squared Error): O modelo GARCH-LSTM obteve melhor desempenho em 12 das 21 ações, enquanto o modelo LSTM Puro se mostrou superior em 9 ações.
- RMSE (Root Mean Squared Error): O modelo GARCH-LSTM apresentou menor RMSE em 14 das ações, comparado ao modelo LSTM Puro, que foi melhor em 7 ações.
- MAE (Mean Absolute Error): Para o MAE, o modelo LSTM Puro apresentou os menores valores em 10 ações, enquanto o modelo GARCH-LSTM foi superior em 11 ações.

Esses resultados indicam que, embora o modelo GARCH-LSTM tenha se destacado em um número maior de ações nos erros MSE e RMSE, a diferença entre os modelos é menos clara quando se considera o MAE, onde os resultados são mais equilibrados. Essa análise reforça a necessidade de uma avaliação cuidadosa ao escolher o modelo mais adequado, considerando as características específicas de cada série temporal e o tipo de erro que é mais relevante para a aplicação em questão. Por outro lado, observa-se que o modelo GARCH-LSTM apresentou melhores resultados para a maioria das ações brasileiras. Isso significa que a inclusão da estimação da volatilidade como uma variável dentro do modelo LSTM, pode trazer melhores previsões do comportamento do preço das ações brasileiras.

Cabe destacar que, neste trabalho, não foram utilizadas validações cruzadas para os erros, o que poderia fornecer uma perspectiva adicional sobre a robustez dos modelos em diferentes partições dos dados. Contudo, em séries temporais, sua aplicação exige cautela, pois as observações têm dependência temporal, e o embaralhamento dos dados, típico da validação cruzada tradicional, pode violar essa dependência. No presente trabalho, optou-se por não utilizar validação cruzada nos erros devido à natureza sequencial dos dados financeiros, em que a preservação da ordem cronológica é fundamental para garantir a integridade das previsões.

A justificativa para o aumento da complexidade do modelo GARCH-LSTM, em comparação com o modelo LSTM puro, está nos ganhos de precisão obtidos. Embora o modelo GARCH-LSTM seja mais complexo devido à adição da estimação de volatilidade, os resultados demonstram que essa complexidade adicional é compensada por previsões mais precisas para a maioria das ações. Por exemplo, a análise gráfica e as métricas de erro indicam que o GARCH-LSTM consegue capturar melhor as flutuações e tendências dos preços. Portanto, a combinação dos modelos justifica o aumento da complexidade, pois proporciona uma melhoria significativa na precisão das previsões, o que é crucial para a tomada de decisões no mercado financeiro. A capacidade do GARCH-LSTM de integrar a volatilidade condicional como uma variável adicional permite uma modelagem mais robusta e detalhada das séries temporais financeiras, resultando em previsões mais confiáveis.

Embora o modelo GARCH-LSTM tenha demonstrado uma melhoria geral na previsão dos preços das ações, houve casos em que o modelo LSTM puro apresentou resultados superiores. Essa observação pode ocorrer pois em alguns casos pode haver um sobreajuste do Modelo GARCH-LSTM que ocorre quando o modelo se ajusta muito bem aos dados históricos, mas perde a capacidade de generalizar para novos dados, resultando em previsões menos precisas. Outro fator que pode explicar essa situação é que algumas ações podem apresentar padrões de volatilidade que são mais estáveis ou menos complexos, tornando a inclusão do modelo GARCH menos benéfica. Nesses casos, o modelo LSTM puro, que se concentra em capturar as dependências temporais dos dados, pode ser mais eficaz.

Cabe elencar que no presente trabalho, utilizou-se como base de dados os valores diários das principais ações de mercado brasileiro. Contudo há um vasto mundo de outros ativos negociados pelo mundo que apresentam características distintas se comparado a essas ações, como a quantidade de negociações diárias, a participação ou não de empresas de HFT (High Frequency Trading) nas negociações dos papéis, tipo de arbitragem, dentre outros. Títulos corporativos, por exemplo, são negociados em uma frequência menor e em volumes maiores do que ações, com diferentes variáveis afetando preço e rendimento. Da mesma forma, moedas e criptomoedas têm suas próprias nuances, e uma rede neural treinada em um tipo de ativo e a generalização deve ser feita com cautela. Além disso, fatores externos, como notícias, mudanças regulatórias, decisões macroeconômicas e até eventos inesperados, podem influenciar diretamente os preços dos ativos. O modelo apresentado, por ser exclusivamente baseado em dados históricos, não incorpora diretamente essas influências externas, mas a integração de variáveis externas, como indicadores macroeconômicos ou análises de sentimento

baseadas em notícias, poderia ampliar sua capacidade de captura dessas dinâmicas.

## 5. CONSIDERAÇÕES FINAIS

O comportamento dos preços no mercado de ações é naturalmente suscetível a instabilidades ocasionadas por fatores econômicos, políticos e sociais, fazendo com que os preços dos ativos financeiros sofram oscilações, denominada volatilidade, e a utilização de modelos de previsões ajudam o investidor no processo de tomada de decisões. Assim, características inerentes às empresas, como preço atual, histórico de preços, retorno diário, variabilidade dos preços, desvio-padrão e estimação da volatilidade, tendem a ser altamente observadas pelos investidores.

No processo de decisão de escolha de ações, há um número finito de ativos que devem ser classificados considerando muitos critérios diferentes e conflitantes. Ao se investir numa determinada ação, os tomadores de decisão devem também considerar diversas outras variáveis para uma escolha mais racional, como perspectiva de ganhos, risco financeiro, probabilidade de perdas e previsões quanto ao comportamento destes ativos.

Desta forma, o presente estudo abordou dois instrumentos utilizados para a estimação do comportamento dos preços das principais ações do mercado de ações brasileiro entre os anos de 2000 e 2024. Ambos os modelos estão inseridos no viés da inteligência artificial onde o primeiro modelo é o de redes neurais LSTM de 15 variáveis, e no outro adiciona-se ao modelo LSTM, uma variável com viés estatístico que é a estimação da volatilidade desses ativos através do modelo GARCH, admitindo que a volatilidade do passado também pode influenciar a estimação do preço das ações para o futuro.

Os resultados encontrados foram sugestivos e apontaram que um modelo do tipo GARCH-LSTM, que incorpora termos de volatilidade condicional ao modelo de redes neurais, seria mais apropriado para se prever o comportamento dos preços da maioria das 21 ações analisadas. Observou-se que a raiz do erro médio ao quadrado (RMSE) encontrado nas estimações, sugeriu que o modelo GARCH-LSTM foi mais indicado para 66,6% das ações; o erro quadrado médio



(MSE), sugeriu uma indicação para 57,1% das empresas; já o erro médio absoluto (MAE) sugeriu que o GARCH-LSTM é indicado para 52,3% das ações.

Apesar das previsões encontradas neste trabalho sugerirem a utilização do modelo GARCH-LSTM, salienta-se que a utilização destes modelos precisam ser usados de forma prudente. Ao se utilizar de modelos de redes neurais, o investidor precisa entender que a cada nova execução do algoritmo, o modelo passa por um novo aprendizado, o que pode por vezes sugerir um modelo em detrimento a outro. Dessa forma, a execução do algoritmo para cada um dos modelos deve ser feita de forma estressante, para que o investidor consiga ter uma média tanto do comportamento dos preços, quanto dos erros encontrados nos resultados. Assim, para um melhor entendimento desta ideia, seria necessário “estressar” cada um dos modelos para cada uma das ações ao longo do tempo e em várias janelas temporais. Uma área de interesse que se encaixa bem com RNNs diz respeito às negociações no mercado de ações baseado nos sentimentos das notícias. Usar RNNs para analisar e classificar rapidamente manchetes de notícias ou relatórios de lucros como positivos ou negativos poderiam agregar os resultados do trabalho. Outro ponto que merece destaque é que, embora a divisão simples entre treino e teste tenha sido utilizada neste estudo, a implementação da validação cruzada poderia melhorar significativamente a robustez e a confiabilidade dos resultados. Estudos futuros podem explorar a aplicação de validação cruzada k-fold ou outras técnicas de validação cruzada para otimizar a avaliação dos modelos de previsão de séries temporais, especialmente em contextos onde a variabilidade estocástica é uma preocupação importante. Por fim, valeria a pena considerar arquiteturas de rede neural alternativas para esse problema. Ajustes na arquitetura atual, como nos hiperparâmetros ou o número de períodos podem agregar os resultados.

Os modelos híbridos GARCH-LSTM têm um grande potencial de aplicação em diversos contextos além dos mercados de ações, como o mercado de criptomoedas (conhecidos por sua alta volatilidade); mercado de commodities como petróleo, ouro e prata; mercado de moedas (Forex); mercado de títulos (Bonds); e o mercado de Energia.

Desta forma, há um grande campo de aplicação para a utilização de modelos de redes neurais LSTM combinados com variáveis de séries temporais, o que pode agregar aos estudos sobre risco e retorno.

## REFERÊNCIAS

Antunes, J. L. F., & Cardoso, M. R. A. (2015). Uso da análise de séries temporais em estudos epidemiológicos. *Epidemiologia e Serviços de Saúde*, 24, 565-576.

BOLLERSLEV, T. Generalized autoregressive conditional heteroskedasticity. **Journal of Econometrics**, Elsevier B.V., v. 31, n. 3, p. 307 – 327, abril 1986. ISSN 0304-4076.

BRESSAN, A. A.; LIMA, J. E. de. Modelos de previsão de preços aplicados aos contratos futuros de boi gordo na BM&F. **Revista Nova Economia**, Editora UFMG, Belo Horizonte, v. 12, n. 1, p. 117 – 140, 2002. ISSN 1980-5381. Disponível em: <https://revistas:face.ufmg.br/index.php/novaeconomia/article/view/396>.

CHUNG, Junyoung et al. Empirical evaluation of gated recurrent neural networks on sequence modeling. **arXiv preprint arXiv:1412.3555**, 2014.

ENDERS, W. **Applied Econometric Time Series**. 4. ed. Hoboken, N.J.: Wiley, 2014. 496 p. ISBN 978-1-118-80856-6.

ENGLE, R. Autoregressive Conditional Heteroscedasticity with Estimates of the Variance of United Kingdom Inflation. **Econometrica: Journal of the Econometric Society**, Econometric Society, the University of Chicago, v. 50, n. 4, p. 987 – 1007, 1982. ISSN 1468-0262.

ENGLE, R. GARCH 101: The Use of ARCH/GARCH Models in Applied Econometrics. **Journal of Economic Perspectives**, American Economic Association, v. 15, n. 4, p. 157 -168, 2001. ISSN 1944-7965.

FARIA, Elisangela Lopes de. Redes neurais convolucionais e máquinas de aprendizado extremo aplicadas ao mercado financeiro brasileiro. 2018.

GAO, Tingwei; CHAI, Yueting; LIU, Yi. Applying long short term memory neural networks for predicting stock closing price. In: **2017 8th IEEE international conference on software**

**engineering and service science (ICSESS)**. IEEE, 2017. p. 575-578.

GERS, Felix A.; SCHMIDHUBER, Jürgen; CUMMINS, Fred. Learning to forget: Continual prediction with LSTM. **Neural computation**, v. 12, n. 10, p. 2451-2471, 2000.

HANSEN, P. R.; LUNDE, A. A forecast comparison of volatility models: does anything beat a GARCH(1,1)? **Journal of Applied Econometrics**, Wiley, v. 20, n. 7, p. 873 – 889, dezembro 2005. ISSN 1099-1255.

HOCHREITER, Sepp; SCHMIDHUBER, Jürgen. Long short-term memory. **Neural computation**, v. 9, n. 8, p. 1735-1780, 1997.

LIU, Wing Ki; SO, Mike KP. A GARCH model with artificial neural networks. **Information**, v. 11, n. 10, p. 489, 2020.

SANG, Chenjie; DI PIERRO, Massimo. Improving trading technical analysis with tensorflow long short-term memory (lstm) neural network. **The Journal of Finance and Data Science**, v. 5, n. 1, p. 1-11, 2019.

Wiener, N. (1966). *Nonlinear problems in random theory*. Cambridge, Massachusetts, USA: The MIT Press.

WILHELMSSON, Anders. GARCH forecasting performance under different distribution assumptions. **Journal of Forecasting**, v. 25, n. 8, p. 561-578, 2006.

XIONG, Ruoxuan; NICHOLS, Eric P.; SHEN, Yuan. Deep learning stock volatility with google domestic trends. **arXiv preprint arXiv:1512.04916**, 2015.